

# Cryptographie et Sécurité

## Série 3 : Entropie

02 Octobre 2019

A rendre exclusivement sur papier, au plus tard au début de la séance du **09 Octobre 2019 et avant 17h15**.

Toutes vos réponses doivent être justifiées.

### Définitions de l'Entropie

Soit une source d'information qui est représentée par une variable aléatoire discrète  $X$  comportant  $n$  symboles, chaque symbole  $x_i$  ayant une probabilité  $p_i$  d'apparaître. Alors l'entropie de la source, notée  $H(X)$ , est définie comme :

$$H(X) = - \sum_{i=1}^n p_i \log_2(p_i) = \sum_{i=1}^n p_i \log_2\left(\frac{1}{p_i}\right)$$

L'entropie est maximale lorsque toutes les probabilités  $p_i$  sont égales. Cela correspond à l'intuition d'une incertitude maximale.

L'entropie jointe pour deux variables aléatoires  $X$  et  $Y$ , notée  $H(X, Y)$  est simplement l'entropie pour toutes les paires  $x, y$  possibles :

$$H(X, Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2(p(x, y))$$

Enfin, l'entropie conditionnelle de  $X$  étant donné  $Y$ , est définie comme suit :

$$H(X|Y) = - \sum_{y \in Y} \sum_{x \in X} p(y)p(x|y) \log_2(p(x|y))$$

L'entropie conditionnelle est très importante en Cryptographie. Par exemple, la valeur  $H(\textit{Plaintext}|\textit{Ciphertext})$  nous donne une idée de l'incertitude qu'on a sur le texte clair lorsqu'on observe le texte chiffré.

## Définition du Codage de Huffman

Le codage de Huffman a pour but d'attribuer les bits de façon efficace aux variables que l'on veut coder. Le but est de construire un arbre binaire de la façon suivante : trier les variables par fréquence, puis fusionner les deux moins fréquentes en une nouvelle variable, et répéter jusqu'à n'avoir plus que deux variables, que l'on trie.

Exemple : Soit les variables A,B,C,D avec probabilités d'apparition respectives 0.2, 0.5, 0.2, 0.1 :

- On ordonne les variables de la plus probable à la moins probable : B, A, C, D.
- On met les deux dernières ensembles :  $E = C, D$ ;  $P(E) = 0.3$ .
- On trie à nouveau : B, E, A.
- On fusionne les deux dernières :  $F = E, A$ ;  $P(F) = 0.5$ .
- Dernier tri : B, F.

On obtient donc le codage suivant :

- $B = 0, F = 1$ .
- Puis on décompose  $F = E, A$  :  $E = 10, A = 11$ .
- Puis on décompose  $E = C, D$  :  $C = 100, D = 101$ .

On obtient donc  $B = 0, A = 11, C = 100, D = 101$ . L'idée est de réduire au maximum l'expression des éléments les plus fréquents.

On peut calculer l'efficacité d'un codage de la manière suivante :

Si  $X$  est une variable aléatoire qui représente les A,B,C,D définis précédemment avec leurs probabilités, l'efficacité  $E$  est définie comme le rapport de l'entropie et de la taille moyenne pour exprimer  $X$  (nombre moyen de bits):

$$E = \frac{H(X)}{\sum_{x \in X} P(x) \cdot \text{nombre de bits pour encoder } x}$$

## Exercice 1 : Entropie

- Soit  $X$  une variable aléatoire prenant les valeurs 0 et 1, avec probabilité  $p_i$  de donner 0 (et  $1 - p_i$  de donner 1, évidemment). Dessinez le graphique de l'entropie selon  $p_i$ , pour  $p_i = 0, p_i = 0.1, p_i = 0.2, \dots, p_i = 0.9, p_i = 1$ .
- Que signifierait une entropie nulle ? Et une entropie infinie ? D'après les définitions, ces deux cas sont-ils possibles ?

## Exercice 2 : Calculs d'Entropie

Soit le système de cryptage symétrique, assez simple, suivant : l'ensemble des plaintexts  $P = \{m_1, m_2, m_3\}$ , l'ensemble des ciphertexts  $C = \{1, 2, 3, 4, 5\}$ , et l'ensemble des clés  $K = \{k_1, k_2, k_3\}$ , avec les règles de chiffrement suivantes :

	$m_1$	$m_2$	$m_3$
$k_1$	3	2	1
$k_2$	4	5	2
$k_3$	1	4	3

On suppose les clés équiprobables, et les plaintexts qui suivent ces probabilités d'apparitions :

$$p(m_1) = \frac{1}{4} \quad p(m_2) = \frac{3}{20} \quad p(m_3) = \frac{6}{10}$$

Calculez les entropies suivantes :

- $H(P)$ .
- $H(K)$ .
- $H(C)$ .
- $H(P|C)$ .

## Exercice 3 : Codage de Huffman

Soit un générateur aléatoire qui génère les caractères A et B (caractères ASCII 8-bit) avec probabilité 0.3 et 0.7 respectivement. Soit  $S^2 = \{AA, AB, BA, BB\}$  la source qui émet les caractères deux à deux (chaque caractère émis par S avec les probabilités définies ci-dessus).

Calculez :

- $H(S)$ .
- $H(S^2)$ .
- Calculez le codage de Huffman pour  $S^2$ .
- Comparez l'efficacité du codage de Huffman avec l'efficacité du codage initial de  $S^2$ .
- Quel est l'intérêt principal du codage de Huffman ?

## Exercice 4 : Entropie d'un Flux Biaisé

Soit un générateur "aléatoire"  $G$  pas très performant, qui génère des 0 et des 1, avec les probabilités  $P(0) = 0.5 + \delta$  et  $P(1) = 0.5 - \delta$ .

On propose de créer un autre générateur aléatoire  $A$  comme suit : on génère deux bits avec  $G$ . Si la séquence est 00 ou 11, on l'ignore et on recommence. Si la séquence est 01, on génère un 0. Si la séquence est 10, on génère un 1.

- Calculez la probabilité de chaque paire (00, 11, 01, 10) d'être générée par  $G$ .
- Calculez la probabilité de 0 et de 1 avec le nouveau générateur  $A$ .
- Calculez combien de bits  $G$  doit générer pour que  $A$  génère  $x$  bits.
- Quel est l'avantage de cette méthode ? Quel est l'inconvénient ?
- Que se passe-t-il si l'algorithme utilise les paires superposées (première paire avec bits 1 et 2, puis deuxième paire avec bits 2 et 3, puis avec bits 3 et 4, etc) ?